Безконтекстни граматики

Една граматика $G = (V, \Sigma, R, S)$ е *безконтекстна*, ако правилата в R имат вида $A \to_G \alpha$, където $A \in V,\ \alpha \in (V \cup \Sigma)^\star$. По този начин, всяко срещане на променливата A в изведена дума може да се замени с α, без значение къде се намира A, т.е. независимо от контекста (оттам е наименованието). Забележете, че α може да е празната дума.

Един език $L \subseteq \Sigma^\star$ е *безконтекстен*, ако съществува безконтекстна граматика G, такава че $L = \mathcal{L}(G) = \{\omega \in \Sigma^\star \mid S \overset{\star}{\Rightarrow}_G \omega\}$.

Пример. Нека G е зададена с правилата $S \to_G AS \mid \epsilon,\ \ A \to_G aAb \mid ab$.
Изводите с начало A имат вида:

$$A \Rightarrow aAb \Rightarrow aaAbb \Rightarrow \ldots \Rightarrow a^nAb^n \Rightarrow a^{n+1}b^{n+1}.$$

Изводите с начало S, в които не се използват правилата с лява част A имат вида:

$$S \Rightarrow AS \Rightarrow A^2S \Rightarrow \ldots \Rightarrow A^nS \Rightarrow A^n.$$

За думата $aabbab \in \mathcal{L}(G)$ да разгледаме следните изводи. Започваме със $S \Rightarrow AS \Rightarrow AAS \Rightarrow AA$ и след това, в зависимост от това коя променлива заместваме, има три начина да продължим:
1. $AA \Rightarrow aAbA \Rightarrow aabbA \Rightarrow aabbab$.
2. $AA \Rightarrow Aab \Rightarrow aAbab \Rightarrow aabbab$.
3. $AA \Rightarrow aAbA \Rightarrow aAbab \Rightarrow aabbab$.

Не е трудно да се съобрази, че $\mathcal{L}(G) = (\{a^nb^n \mid n > 0\})^\star$. Забележете, че всяка дума от $\mathcal{L}(G)$ може да се представи по единствен начин като конкатенация на думи от $\{a^nb^n \mid n > 0\}$.

Твърдение 1 (Основно твърдение за безконтекстни граматики) *Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика и $\gamma_1\gamma_2 \overset{\ell}{\Rightarrow}_G \beta$, където $\ell \in \mathbb{N}$ и $\gamma_1, \gamma_2, \beta \in (V \cup \Sigma)^\star$. Тогава съществуват $\ell_1, \ell_2 \in \mathbb{N}$ и $\beta_1, \beta_2 \in (V \cup \Sigma)^\star$, такива че $\gamma_1 \overset{\ell_1}{\Rightarrow}_G \beta_1$, $\gamma_2 \overset{\ell_2}{\Rightarrow}_G \beta_2$, $\ell_1 + \ell_2 = \ell$ и $\beta_1\beta_2 = \beta$.*

Доказателство. Индукция по дължината на извода ℓ.

- Нека $\ell = 0$. Тогава $\gamma_1\gamma_2 = \beta$ и взимаме $\ell_1 = \ell_2 = 0$, $\beta_1 = \gamma_1$ и $\beta_2 = \gamma_2$.
- Нека $\ell > 0$. Тогава за някое правило $A \to_G \alpha$ имаме следната ситуация:

$$\gamma_1\gamma_2 \ = \ \lambda A\rho \ \Rightarrow_G \ \lambda\alpha\rho \ \overset{\ell-1}{\Rightarrow} \ \beta.$$

  Да разгледаме първо случая, в който променливата A е част от γ_1. Това означава, че можем да запишем $\gamma_1 = \lambda A\rho_1$ и $\rho = \rho_1\gamma_2$ за някоя дума ρ_1. Да означим $\gamma_1' = \lambda\alpha\rho_1$. Това означава, че $\gamma_1'\gamma_2 = \lambda\alpha\rho$ и така имаме извода $\gamma_1'\gamma_2 \overset{\ell-1}{\Rightarrow} \beta$.

Прилагаме индукционното предположение към този извод и заключаваме, че съществуват представяне $\beta = \beta_1\beta_2$ и следните два извода:

$$\gamma_1' \overset{\ell_1'}{\Rightarrow} \beta_1, \quad \gamma_2 \overset{\ell_2}{\Rightarrow} \beta_2$$

за числа ℓ_1' и ℓ_2, такива че $\ell_1' + \ell_2 = \ell - 1$. Остава да добавим γ_1 най-отпред в първия извод:

$$\underbrace{\lambda A \rho_1}_{\gamma_1} \Rightarrow_G \underbrace{\lambda \alpha \rho_1}_{\gamma_1'} \overset{\ell_1'}{\Rightarrow} \beta_1,$$

което дава $\gamma_1 \overset{\ell_1}{\Rightarrow} \beta_1$ за $\ell_1 = \ell_1' + 1$.

Другият случай, когато A е част от γ_2 е симетричен.

Забележете, че в произволна граматика от изводите $\gamma_1 \overset{\ell_1}{\Rightarrow}_G \beta_1$, $\gamma_2 \overset{\ell_2}{\Rightarrow}_G \beta_2$ може да се построи изводът $\gamma_1\gamma_2 \overset{\ell_1+\ell_2}{\Rightarrow}_G \beta_1\beta_2$. Основното твърдение показва обратното, т.е. прави се подходящо разбиване на извода $\gamma_1\gamma_2 \overset{\ell}{\Rightarrow}_G \beta$ и тук вече е съществено, че граматиката G е безконтекстна. Лявата част на правилото $A \to \alpha$, което първо се прилага в извода е част или от γ_1, или от γ_2, не може да се припокрива и с двете думи.

Следствие 2 *Нека G е безконтекстна граматика и $X_1X_2\ldots X_k \overset{\ell}{\Rightarrow}_G \beta$, където $X_i \in V \cup \Sigma$. Съществуват думи $\beta_1, \beta_2, \ldots, \beta_k$ и естествени числа $\ell_1, \ell_2, \ldots, \ell_k$, такива че $X_i \overset{\ell_i}{\Rightarrow}_G \beta_i$, $\beta = \beta_1\beta_2\ldots\beta_k$ и $\ell = \ell_1 + \ell_2 + \ldots + \ell_k$.*

Доказателство. Индукция по k. Разбира се, ако $X_i \in \Sigma$, то $\beta_i = X_i$ и $\ell_i = 0$.

Твърдение 3 *Безконтекстните езици са затворени относно регулярните операции обединение, конкатенация и звезда на Клини.*

Доказателство. Нека S_1 и S_2 са аксиомите на двете граматики (считаме, че те нямат общи променливи). Създаваме нова аксиома S и в зависимост от операцията добавяме следните правила:

- за обединение: $S \to S_1,\ S \to S_2$
- за конкатенация: $S \to S_1S_2$
- за звезда на Клини: $S \to S_1S \mid \epsilon$

Забележете, че при конкатенация, от $S \overset{\star}{\Rightarrow} \alpha$ и основното твърдение получаваме, че съществува съответно разбиване $\alpha = \alpha_1\alpha_2$, където $S_1 \overset{\star}{\Rightarrow} \alpha_1$ и $S_2 \overset{\star}{\Rightarrow} \alpha_2$. Подобно разсъждение е необходимо също при звездата на Клини.

Следствие 4 *Всички регулярни езици са безконтекстни.*

Доказателство. Индукция по регулярните езици с използване на твърдението. Базовите езици са безконтекстни: $S \to \epsilon$ поражда $\{\epsilon\}$, $S \to S$ поражда $\emptyset$ и $S \to a$ поражда $\{a\}$. Алтернативен начин за доказателство е да се съобрази, че всяка регулярна граматика е безконтекстна.

Синтактични дървета

Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика.

Ще дефинираме *дърво на извод* (T, λ), съвместимо с граматиката G:

1. T е крайно дърво с корен r с наредба на синовете, т.е. за всеки връх v имаме, че множеството $succ_T(v)$ от неговите синове (преките наследници) е линейно наредено.

2. $\lambda : T \to V \cup \Sigma \cup \{\epsilon\}$ е функция, задаваща етикети по върховете.

3. За корена r имаме $\lambda(r) \neq \epsilon$, т.е. $\lambda(r) \in V \cup \Sigma$.

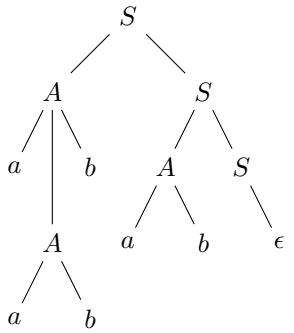
4. Нека v е връх в T, който не е листо и $succ_T(v) = \{w_1, \ldots, w_k\}$, $k \geq 1$ са неговите синове, подредени с нарастващи индекси. Съвместимостта на (T, λ) с граматиката G изисква $\lambda(v) \to_G \lambda(w_1) \ldots \lambda(w_k)$ да е правило в G.

5. Връх w с етикет ϵ се допуска само за листата и то ако бащата v на w няма други синове, т.е. при $succ_T(v) = \{w\}$ и правило $\lambda(v) \to_G \epsilon$ се допуска $\lambda(w) = \epsilon$ (и само в такъв случай).

6. Нека $l_1, l_2, \ldots, l_k$ са всички листа на дървото, обходени отляво надясно. По-точно обхождането е в дълбочина на принципа пръв (най-ляв) необходен. Тогава ще казваме, че дървото (T, λ) извежда думата

$$yield(T, \lambda) = \lambda(l_1)\lambda(l_2) \ldots \lambda(l_k).$$

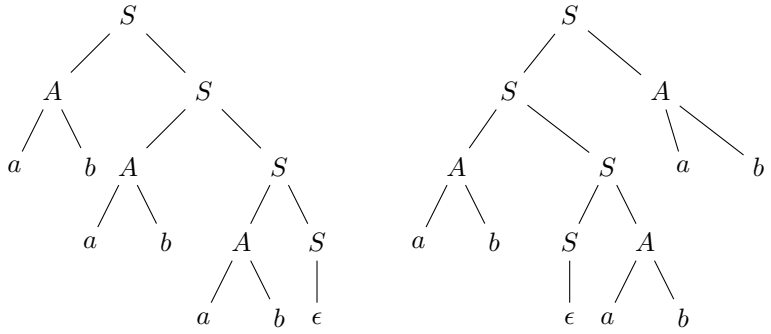
Да се върнем към горния пример. Там показахме три различни линейни изводи на думата $aabbab \in \mathcal{L}(G)$. Но на тях съответства едно и също дърво на извод:



По-общо може да се покаже, че граматиката G в примера е *еднозначна*, т.е. за всяка дума от $\mathcal{L}(G)$ има единствено дърво за извод. Причината е, че за всяка дума $\alpha \in \mathcal{L}(G)$ съществуват единствено естествено k и думи

$\alpha_1, \alpha_2, \ldots, \alpha_k \in \{a^n b^n \mid n > 0\}$, такива че $\alpha = \alpha_1 \alpha_2 \ldots \alpha_k$. Това определя, че по най-десния клон на дървото има точно $k+1$ върха с етикет S и накрая едно листо с етикет ϵ. От първите k от тези върхове отляво се поставят последователно единствените дървета с корен A, които извеждат думите α_i за $i = 1, 2, \ldots, k$.

Като алтернативен пример да добавим ново правило $S \to SA$ в граматиката G. Тогава отново $\mathcal{L}(G) = (\{a^n b^n \mid n > 0\})^\star$, но граматиката вече не е еднозначна. Например, за думата $ababab \in \mathcal{L}(G)$ имаме следните различни дървета на извод:



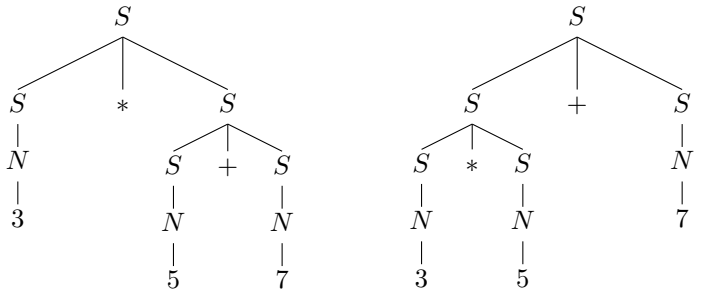
За домашно намерете всички останали дървета на извод на думата *ababab*, както и на горната дума *aabbab*.

Защо е важна еднозначността? Най-общо казано искаме една граматика да е еднозначна, ако дефинираме стойности върху изведените думи с помощта на дърветата на извод.

Като пример да разгледаме граматиката

$$S \to S + S \mid S * S \mid N, \quad N \to 0 \mid 1 \mid \ \ldots \ \mid 9.$$

Тя се състои от аритметичните изрази без скоби върху операнди с по една цифра. По-долу са показани двете дървета на извод за думата $3 * 5 + 7$. Пресмятането на израза с дървото отляво дава погрешен резултат 36, докато дървото отдясно дава точния резултат 22.



Един вариант е да въведем скоби в изразите:

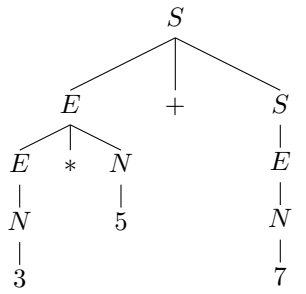
$$S \to (S + S) \mid (S * S) \mid N.$$

По този начин получаваме еднозначна граматика, но с цената на промяна на езика. На горния израз $3 * 5 + 7$ съответстват двата различни израза $(3 * (5 + 7))$ и $((3 * 5) + 7)$, в които изрично е посочен редът на операциите.

По-добрият вариант, при който запазваме езика, е да въведем приоритет на $*$ пред $+$ по следния начин:

$$S \to E + S \mid E, \quad E \to E * N \mid N.$$

Езикът на граматиката не се променя, но тя вече е еднозначна. Единственото дърво на извод на израза $3 * 5 + 7$ е:



Оказва се, че задачата която решихме за конкретната граматика в общия случай е неразрешима. Не съществува алгоритъм, който разпознава дали дадена безконтекстна граматика е еднозначна.

Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика.

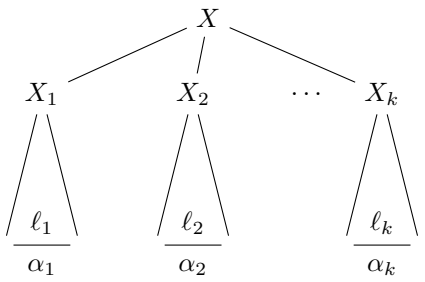
Дефиниция 5 *За $\ell \in \mathbb{N}$, $X \in V \cup \Sigma$, $\alpha \in (V \cup \Sigma)^\star$ въвеждаме релацията $X \overset{\ell}{\lhd} \alpha$ за дървовиден извод с пълна индукция по ℓ:*

- *При $\ell = 0$ допускаме само $X \overset{0}{\lhd} X$, т.е. $\alpha = X$.*
- *Нека $X_1 \overset{\ell_1}{\lhd} \alpha_1$, $X_2 \overset{\ell_2}{\lhd} \alpha_2$, $\ldots$, $X_k \overset{\ell_k}{\lhd} \alpha_k$ и $X \to_G X_1 X_2 \ldots X_k$ е правило. Тогава е в сила релацията $X \overset{\ell}{\lhd} \alpha$, където $\ell = \max(\ell_1, \ell_2, \ldots, \ell_k) + 1$ и $\alpha = \alpha_1 \alpha_2 \cdots \alpha_k$.*

Интуицията за релацията $X \overset{\ell}{\lhd} \alpha$ е следната: съществува дърво на извод (T, λ) с *височина* l, което е съвместимо с граматиката G, коренът му има етикет X и $yield(T, \lambda) = \alpha$ (по листата отляво надясно се извежда α).

За всяко $X \in V \cup \Sigma$ имаме $X \overset{0}{\lhd} X$, което съответства на тривиалното дърво с корен X и височина 0, извеждащо думата $\alpha = X$.

Също така при дадени дървета на извод, съществуващи от релациите $X_1 \overset{\ell_1}{\lhd} \alpha_1, X_2 \overset{\ell_2}{\lhd} \alpha_2, \ldots, X_k \overset{\ell_k}{\lhd} \alpha_k$ можем да образуваме ново дърво на извод, съответно на релацията $X \overset{\ell}{\lhd} \alpha$ по следния начин: коренът има етикет X, неговите синове са корените $X_1, X_2, \ldots, X_k$ на дадените дървета, присъединени в този ред отляво надясно. Разбира се, за да е коректно новото дърво на извод е необходимо $X \to_G X_1 X_2 \ldots X_k$ да бъде правило в граматиката. Височината на новото дърво е $\ell = \max(\ell_1, \ell_2, \ldots, \ell_k) + 1$ и думата, която то извежда е $\alpha = \alpha_1 \alpha_2 \ldots \alpha_k$.



Като частен случай, при наличие на правило $X \to_G \epsilon$ имаме $X \overset{1}{\lhd} \epsilon$. Това е единствената възможност, в която $k = 0$ (приемаме, че максимумът на празното множество е 0).

Съобразете по-общо, че ако имаме правило $X \to_G \alpha$, то $X \overset{1}{\lhd} \alpha$.

Подобно на дефинициите и в други случаи: $X \overset{\star}{\lhd} \alpha$ ще означава, че съществува $\ell \in \mathbb{N}$, такова че $X \overset{\ell}{\lhd} \alpha$.

Нашата непосредствена цел е да видим, че релациите $X \overset{\star}{\lhd} \alpha$ и $X \overset{\star}{\Rightarrow} \alpha$ са еквивалентни.

Твърдение 6 *Нека G е безконтекстна граматика, $X \in V \cup \Sigma$ и $\alpha \in (V \cup \Sigma)^\star$. Тогава ако $X \overset{\star}{\Rightarrow} \alpha$, то $X \overset{\star}{\lhd} \alpha$.*

Доказателство. С пълна индукция по ℓ ще докажем, че ако $X \overset{\ell}{\Rightarrow} \alpha$, то $X \overset{\star}{\lhd} \alpha$.

- Базата е при $\ell = 0$, т.е. $X \overset{0}{\Rightarrow} X$. Тогава е ясно, че $X \overset{\star}{\lhd} X$ ($X \overset{0}{\lhd} X$).
- Нека $\ell > 0$ и $X \overset{\ell}{\Rightarrow} \alpha$. Нека първото приложено правило в този извод е $X \to_G X_1 X_2 \cdots X_k$, където $X_i \in V \cup \Sigma$. Тогава имаме:

  $$X \;\Rightarrow\; X_1 X_2 \cdots X_k \;\overset{\ell-1}{\Rightarrow}\; \alpha.$$

  От следствието от основното твърдение знаем, че съществува разбиване на α на k части, така че:

– $\alpha = \alpha_1\alpha_2\cdots\alpha_k$;

– $X_i \overset{\ell_i}{\Rightarrow} \alpha_i$ за $i = 1, 2, \ldots, k$;

– $\ell - 1 = \sum_{i=1}^{k} \ell_i$.

Понеже $\ell_i < \ell$ за всяко $i = 1, 2, \ldots, k$ можем да използваме индукционното предположение и получаваме:

$$X_1 \overset{\star}{\lhd} \alpha_1, \;\; X_2 \overset{\star}{\lhd} \alpha_2, \;\; \ldots, \;\; X_k \overset{\star}{\lhd} \alpha_k.$$

От дефиницията за дървовиден извод и от наличието на правилото $X \to_G X_1 \cdots X_k$ заключаваме, че $X \overset{\star}{\lhd} \alpha$.

Забележете, че височината на дървото, което съответства на линейния извод с дължина ℓ е в общия случай доста по-малка от ℓ.

Твърдение 7 *Нека G е безконтекстна граматика, $X \in V \cup \Sigma$ и $\alpha \in (V \cup \Sigma)^\star$. Тогава ако $X \overset{\star}{\lhd} \alpha$, то $X \overset{\star}{\Rightarrow} \alpha$.*

Доказателство. С пълна индукция по ℓ ще докажем, че ако $X \overset{\ell}{\lhd} \alpha$, то $X \overset{\star}{\Rightarrow} \alpha$.

- Нека $\ell = 0$. Това означава, че $X \overset{0}{\lhd} X$ и е ясно, че $X \overset{\star}{\Rightarrow} X$ ($X \overset{0}{\Rightarrow} X$).

- Нека $\ell > 0$ и $X \overset{\ell}{\lhd} \alpha$. Тогава имаме правило $X \to_G X_1X_2\cdots X_k$ и релациите $X_1 \overset{\ell_1}{\lhd} \alpha_1$, $X_2 \overset{\ell_2}{\lhd} \alpha_2$, $\ldots$, $X_k \overset{\ell_k}{\lhd} \alpha_k$, за които $\ell = 1 + \max(\ell_1, \ell_2, \ldots, \ell_k)$ и $\alpha = \alpha_1\alpha_2\ldots\alpha_k$. В частност, $\ell_i < \ell$ за всяко $i = 1, 2, \ldots, k$ и от индукционното предположение:

  $$X_1 \overset{\star}{\Rightarrow} \alpha_1, \;\; X_2 \overset{\star}{\Rightarrow} \alpha_2, \;\; \ldots, \;\; X_k \overset{\star}{\Rightarrow} \alpha_k.$$

  Остава да съединим тези k на брой изводи:

  $$X \;\Rightarrow\; X_1X_2\cdots X_k \;\overset{\star}{\Rightarrow} \alpha_1X_2\cdots X_k \;\; \overset{\star}{\Rightarrow} \alpha_1\alpha_2\cdots X_k \;\overset{\star}{\Rightarrow} \ldots \;\overset{\star}{\Rightarrow} \alpha_1\alpha_2\cdots\alpha_k.$$

  Окончателно, $X \overset{\star}{\Rightarrow} \alpha$.

Забележете, че в индукционната стъпка свързахме k на брой линейни извода в един извод, чиято дължина е *сумата* на дължините на дадените k извода (плюс 1).

Всъщност може лесно да се съобрази, че дължината на един линеен извод, съответен на дадено дърво на извод, е равна на броя на всички върхове в дървото, които не са листа. Височината на дървото е дължината на максимален прост път от корена до някое листо и затова в общия случай е доста по-малка от дължината на линейния извод.

Материалът за осмата лекция от записките на Вътев:
глава 3.4 (**Безконтекстни граматики**), страници 105-107,
глава 3.5 (**Синтактични дървета**), страници 108-109,
глава 3.6 (**Извод върху синтактично дърво**), страници 110-113.

За допълнително четене от учебника на Hopcroft, Motwani, Ullman:
глава 5.1 (Context-Free Grammars), подглави 5.1.1, 5.1.2, 5.1.3, 5.1.5,
глава 5.2 (Parse Trees), подглави 5.2.1, 5.2.2, 5.2.4, 5.2.5,
глава 5.4 (Ambiguity in Grammars and Languages), подглави 5.4.1, 5.4.2.