Започнахме лекцията с построяване на безконтекстна граматика за следния език:

$$L \;=\; \{a^n b^k c^{n+k} \mid n, k \in \mathbb{N}\}.$$

Стана ясно, че е много важно по какъв начин разделяме думата, за да можем да я генерираме в граматиката. Например, разделянето $a^n b^k c^n c^k$ не е подходящо, тъй като двете части зависещи от n са кръстосани с двете части зависещи от k. Не е възможно запомнянето на стойността на k, докато генерираме частите зависещи от n.

Затова подходящото разделяне е $a^n b^k c^k c^n$. Тук двете части отново се застъпват, но не са кръстосани и могат да се генерират независимо. В началото генерираме от аксиомата S началото a^n и края c^n едновременно. След това с помощта на променливата B вмъкваме между тях думата $b^k c^k$. По-точно ще използваме следната граматика:

$$S \to aSc \mid B, \quad B \to bBc \mid \epsilon.$$

Когато конструираме директно дадена граматика (без да използваме общи конструкции) е необходимо да дадем доказателство за коректността на граматиката.

По аналогия с десните езици на състояния на краен автомат, дефинираме *език на променлива* $X \in V$ да бъде:

$$\mathcal{L}_G(X) \;=\; \{\omega \in \Sigma^\star \mid X \overset{\star}{\Rightarrow} \omega\} \;=\; \{\omega \in \Sigma^\star \mid X \overset{\star}{\lhd} \omega\}.$$

За горната граматика първо ще проверим, че $\mathcal{L}_G(B) \;=\; \{b^k c^k \mid k \in \mathbb{N}\}$.

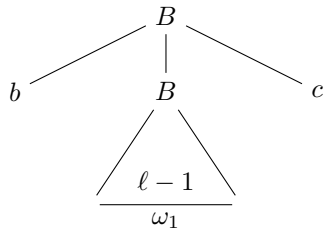
1. За посоката $\subseteq$. С индукция по ℓ ще покажем:

$$B \overset{\ell}{\lhd} \omega,\ \omega \in \Sigma^\star \quad \text{влече} \quad \omega = b^k c^k \text{ за някое } k.$$

При $\ell = 0$ предпоставката не е вярна, така че цялата импликация е вярна. При $\ell = 1$ единствено е възможно $\omega = \epsilon$, тъй като няма други правила с лява част B и дясна част от $\Sigma^\star$ освен $B \to \epsilon$. Дървото на извод изглежда така:

$$\begin{array}{c} B \\ | \\ \epsilon \end{array}$$

Разбира се в случая $\omega = \epsilon = b^0 c^0$ и можем да вземем $k = 0$. По-нататък, нека $\ell > 1$ и $B \overset{\ell}{\lhd} \omega$, $\omega \in \Sigma^\star$. Тогава първото приложено правило е $B \to bBc$ и новата променлива B генерира дума $\omega_1 \in \Sigma^\star$, такава че $\omega = b\omega_1 c$. Дървото на извод изглежда така:



Тъй като $B \overset{\ell-1}{\lhd} \omega_1$, от индукционното предположение $\omega_1 = b^k c^k$ за някое $k \in \mathbb{N}$. Тогава $\omega = b\omega_1 c = b^{k+1}c^{k+1}$, с което индукцията е завършена.

2. За посоката $\supseteq$. С индукция по k ще покажем, че $b^k c^k \in \mathcal{L}_G(B)$. Тук е по-удобно да използваме линеен извод, т.е. $B \overset{\star}{\Rightarrow} b^k c^k$. При $k = 0$ имаме $B \overset{\star}{\Rightarrow} b^0 c^0 = \epsilon$ заради правилото $B \to \epsilon$. След това да допуснем, че $B \overset{\star}{\Rightarrow} b^k c^k$ за някое k. Тогава с правилото $B \to bBc$ получаваме $B \Rightarrow bBc \overset{\star}{\Rightarrow} b^{k+1}c^{k+1}$.

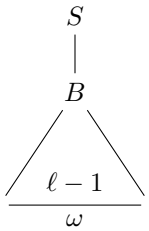
Първата част показа, че всички изведени думи от B имат необходимия вид $b^k c^k$. Втората част показа, че всяка дума $b^k c^k$ може да се изведе от B.

След тази подготовка ще проверим, че $\mathcal{L}_G(S) = \{a^n b^k c^{n+k} \mid n, k \in \mathbb{N}\}$.

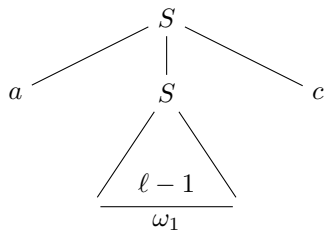
1. За посоката $\subseteq$. С индукция по ℓ ще покажем:

$$S \overset{\ell}{\lhd} \omega,\ \omega \in \Sigma^\star \quad \text{влече} \quad \omega = a^n b^k c^{n+k} \text{ за някои } n, k.$$

При $\ell = 0, 1$ импликацията е тривиално вярна (няма такава дума ω). Нека $\ell > 1$ и $S \overset{\ell}{\lhd} \omega$, $\omega \in \Sigma^\star$. Имаме два случая в зависимост от първото приложено правило. **1)** Нека то е $S \to B$. Тогава дървото има вида:



Тъй като $B \overset{\ell-1}{\lhd} \omega$, имаме $\omega \in L_G(B)$ и по-горе показахме, че в такъв случай $\omega = b^k c^k = a^0 b^k c^{0+k}$. Така ω има нужния вид при $n = 0$. **2)** Нека сега въпросното първо правило е $S \to aSc$. Новата променлива S генерира дума $\omega_1 \in \Sigma^\star$, такава че $\omega = a\omega_1 c$. Дървото на извод изглежда така:



Имаме $S \overset{\ell-1}{\lhd} \omega_1$, така че от индукционното предположение $\omega_1 = a^n b^k c^{n+k}$ за някои n, k. Следователно, $\omega = a\omega_1 c = a^{n+1} b^k c^{n+1+k}$ и индукцията е завършена.

2. За посоката $\supseteq$. За домашно с индукция по n покажете, че за произволно $k \in \mathbb{N}$ е изпълнено $a^n b^k c^{n+k} \in \mathcal{L}(G) = \mathcal{L}_G(S)$.

В посочения пример, първо успяхме да намерим езика на променливата B и след това на аксиомата S. При по-сложни примери може да се наложи да проверяваме с едновременна индукция няколко хипотези за езиците на различни променливи.

Лема за покачването за безконтекстни езици

Лемата за покачването ще позволи да покажем примери за езици, които не са безконтекстни.

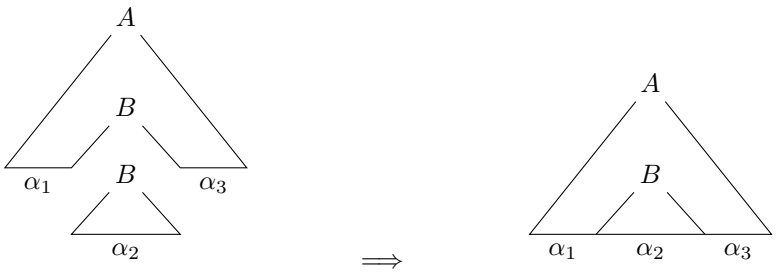
Подобно на лемата за покачване за регулярни езици, тя е необходимо но не и достатъчно условие за това един език да е безконтекстен.

Логическият вид на формулировката на двете леми е много подобен, но покачването в една дума при безконтекстни езици се случва на две места.

Първо ще разгледаме три помощни твърдения.

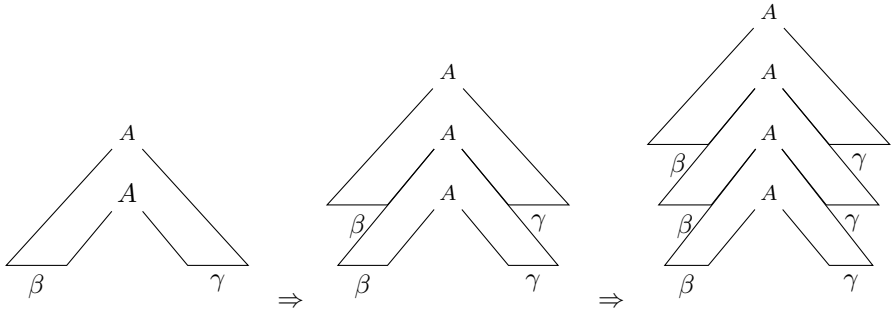
Твърдение 1 *Нека* $A \overset{\ell_1}{\lhd} \alpha_1 B \alpha_3$ *и* $B \overset{\ell_2}{\lhd} \alpha_2$. *Тогава* $A \overset{\leq \ell_1+\ell_2}{\lhd} \alpha_1\alpha_2\alpha_3$.

Доказателство. Идеята тук е, че B е листо в първото дърво и в него закачваме второто дърво, което има корен B. Височината на новото дърво съвпада или с ℓ_1 или със сумата на ℓ_2 и височината на листото B в първото дърво. И в двата случая тя е $\leq \ell_1 + \ell_2$. Формалното доказателство ще бъде с индукция по ℓ_1. Картинката е следната (от двете дървета вляво получаваме дървото, което е вдясно):



Твърдение 2 *Нека* $A \overset{\ell}{\lhd} \beta A \gamma$. *Тогава за всяко* $i \in \mathbb{N}$: $A \overset{\leq \ell.i}{\lhd} \beta^i A \gamma^i$.

Доказателство. Индукция по i с използване на предходното твърдение. Даденото дърво размножаваме i пъти на мястото на листото A. Картинката при $i = 3$ е следната:



Твърдение 3 *Нека* G *е безконтекстна граматика и*

$$b \;=\; \max\{\, |\gamma| \mid A \to \gamma \text{ е правило в } G\}.$$

1. *Ако* $A \overset{\leq \ell}{\lhd} \alpha$, *то* $|\alpha| \leq b^\ell$.
2. *Ако* $\alpha \in \mathcal{L}(G)$ *и* $|\alpha| > b^\ell$, *то* $S \overset{\geq \ell+1}{\lhd} \alpha$.

Доказателство. 1. Имаме дърво на извод (T, λ) с корен A и $yield(T, \lambda) = \alpha$, като височината на T е $\leq \ell$. Също така, разклонеността на T е $\leq b$, тъй като броят на синовете на всеки връх е или 0 или съвпада с дължината на някоя дясна част на правило в граматиката. От теорема от първия семестър знаем, че в такъв случай броят на листата на T не надминава b^ℓ. Разбира се, това означава, че $|\alpha| \leq b^\ell$.

2. Ако $\alpha \in \mathcal{L}(G)$, то $S \overset{\star}{\lhd} \alpha$, т.е. $S \overset{k}{\lhd} \alpha$ за някое k. Тъй като $|\alpha| > b^\ell$, от първата част не е възможно $k \leq \ell$.

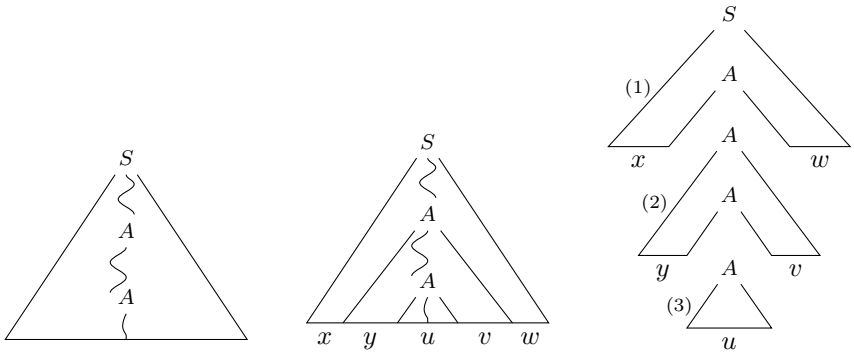
Лема 4 (за покачването за безконтекстни езици) *За всеки безконтекстен език* L *съществува естествено число* $p \geq 1$, *такова че за всяка дума* $\alpha \in L$ *с* $|\alpha| \geq p$ *съществува разбиване на пет части* $\alpha = xuvvw$, *такива че: 1)* $|yv| \geq 1$; *2)* $|yuv| \leq p$; *3) за всяко* $i \in \mathbb{N}$, $xy^iuv^iw \in L$.

Доказателство. Нека $L = \mathcal{L}(G)$, където $G = (V, \Sigma, R, S)$ е безконтекстна граматика. Да положим

$$p \;=\; b^{|V|+1}, \text{ където } b \;=\; \max\{\, |\gamma| \mid A \to \gamma \text{ е правило в } G \,\}.$$

Ще покажем, че този избор на p е подходящ за удовлетворяването на условията на лемата.

Нека $\alpha \in L$ е произволна дума, такава че $|\alpha| \geq p$. Избираме дърво на извод (T, λ) за α с корен S и *минимален* брой върхове. Нека ℓ е неговата височина. Тъй като $|\alpha| > b^{|V|}$, от Твърдение 3 получаваме $\ell \geq |V| + 1$. По-нататък избираме *максимален* път в T. Етикетите по върховете му са $X_0, X_1, \ldots, X_\ell$, където $X_i \in V$ за $i < \ell$ и $X_\ell \in \Sigma \cup \{\varepsilon\}$. Щом $\ell \geq |V| + 1$, по този път се срещат поне $|V| + 1$ на брой променливи. От принципа на Дирихле получаваме, че върху пътя трябва да има поне едно повторение на променливи. Избираме такова повторение (A, A) за променлива A, което е най-близо до края на пътя. Сега можем да разбием извода $S \overset{\ell}{\lhd} \alpha$ като $S \overset{\star}{\lhd} xAw$ (първото A е листо) и $A \overset{\leq |V|+1}{\lhd} \gamma$, където $\alpha = x\gamma w$. Височината на последното дърво не надминава $|V| + 1$, иначе ще има друго повторение на променливи по избрания път, което е по-близо до края на пътя. След това извода $A \overset{\leq |V|+1}{\lhd} \gamma$ го разбиваме като $A \overset{\leq |V|+1}{\lhd} yAv$ (коренът е първото A, второто A е листо) и $A \overset{\star}{\lhd} u$ (коренът е второто A), където $\gamma = yuv$. Картинката е следната:



(а) Първата двойка повтарящи се променливи, която е най-близо до края на избрания път.

(б) Разбиваме дървото на три части.

(в) Получаваме три отделни синтактични дървета.

Разбихме думата α на пет части като $\alpha = xyuvw$ и остава да проверим трите условия.

- Да допуснем, че $|yv| = 0$. Това означава, че $\alpha = xuw$ и имаме изводите: $S \overset{\star}{\lhd} xAw$, $A \overset{\star}{\lhd} u$. Като ги комбинираме получаваме $S \overset{\star}{\lhd} xuw = \alpha$ с дърво на извод с по-малко на брой върхове отколкото T, защото махаме средната част, която съдържа поне един връх (с етикет A). Това противоречи на избора на T като синтактично дърво за $S \overset{\star}{\lhd} \alpha$ с минимален брой върхове. Заключаваме, че $|yv| \geq 1$.

- Имаме извода $A \overset{\leq |V|+1}{\lhd} yuv$ и от Твърдение 3, $|yuv| \leq b^{|V|+1} = p$.

- От $A \overset{\star}{\lhd} yAv$ с Твърдение 2 получаваме, че за произволно i, $A \overset{\star}{\lhd} y^i A v^i$. Също така, $A \overset{\star}{\lhd} u$ и значи $A \overset{\star}{\lhd} y^i u v^i$. Остава да използваме $S \overset{\star}{\lhd} xAw$ и окончателно $S \overset{\star}{\lhd} xy^i uv^i w$, т.е. за всяко i, $xy^i uv^i w \in \mathcal{L}(G) = L$.

Както при лемата за покачване за регулярни езици, ние ще използваме контрапозицията на лемата като достатъчно условие, че даден език не е безконтекстен.

Следствие 5 *Нека L е произволен език, за който е изпълнено:*

(∀) *за* всяко *естествено число $p \geq 1$,*

(∃) *можем да намерим дума $\alpha \in L$, $|\alpha| \geq p$, такава че*

(∀) *за* всяко *разбиване на думата на пет части, $\alpha = xyuvw$, със свойствата $|yv| \geq 1$ и $|yuv| \leq p$,*

(∃) *можем да намерим $i \in \mathbb{N}$, за което е изпълнено, че $xy^i uv^i w \notin L$.*

Тогава L **не** *е безконтекстен език.*

Пример. Нека $L = \{a^n b^n c^n \mid n \in \mathbb{N}\}$. За произволно $p \geq 1$ да вземем думата $\alpha = a^p b^p c^p \in L$. Нека $\alpha = xyuvw$ е произволно разбиване на α, такова че $|yv| \geq 1$ и $|yuv| \leq p$. Забележете, че не е възможно yuv да съдържа и трите букви a, b, c, но може да съдържа две от тези букви. Това означава, че за всяко $i \neq 1$ в думата $xy^i uv^i w$ една от буквите се среща точно толкова пъти, колкото в α, но поне една от другите две букви се среща повече (при $i > 1$) или по-малко (при $i = 0$) на брой пъти отколкото в α. Така при всяко $i \neq 1$ (а на нас ни е достатъчна дори само една подходяща стойност на i) имаме $xy^i uv^i w \notin L$. От следствието получаваме, че L не е безконтекстен език.

Твърдение 6 *Класът на безконтекстните езици не е затворен относно сечение.*

Доказателство. Да разгледаме езиците $L_1 = \{a^n b^n c^m \mid n, m \in \mathbb{N}\}$ и $L_2 = \{a^m b^n c^n \mid n, m \in \mathbb{N}\}$. Лесно се съобразява, че те са безконтекстни: $L_1 = \{a^n b^n \mid n \in \mathbb{N}\} \cdot c^\star$ и подобно за $L_2 = a^\star \cdot \{b^n c^n \mid n \in \mathbb{N}\}$. От друга страна, $L_1 \cap L_2 = L$, където L е езикът от горния пример.

Твърдение 7 *Класът на безконтекстните езици не е затворен относно допълнение.*

Доказателство. Това следва от факта, че безконтекстните езици са затворени относно обединение. Ако бяха затворени относно допълнение, то от законите на Де Морган щяха да са затворени и относно сечение, което проверихме, че не е вярно.

Може да се посочат и конкретни примери. За домашно покажете, че $\overline{L}$ е безконтекстен език, където L е езикът от примера.

Друг пример, разгледан в записките е езикът $L = \{\alpha\alpha \mid \alpha \in \{a,b\}^\star\}$, който не е безконтекстен, но неговото допълнение се оказва безконтекстен език.

Както при регулярни езици, съществуването на числото p от лемата за покачването дава методи за проверка за празнота, както и за безкрайност на езика на безконтекстна граматика:

$$\mathcal{L}(G) \neq \emptyset \iff \exists \alpha \in \mathcal{L}(G)\ |\alpha| < p,$$

$$|\mathcal{L}(G)| = \infty \iff \exists \alpha \in \mathcal{L}(G)\ p \leq |\alpha| < 2p.$$

Доказателствата са напълно аналогично на тези при регулярни езици. По този начин, проблемите за празнота и за безкрайност се свеждат до краен брой проверки на проблема за принадлежност: при дадени безконтекстна G и $\alpha \in \Sigma^\star$ дали $\alpha \in L(G)$? За този проблем ще видим ефективен алгоритъм в следващата лекция.

За разлика от регулярните езици, обаче, за редица проблеми се оказва, че не съществуват алгоритми: проблемът по дадена безконтекстна G, дали $\mathcal{L}(G) = \Sigma^\star$? (т.е. дали G извежда всички думи) се оказва неразрешим; подобно за проблемите $\mathcal{L}(G_1) \subseteq \mathcal{L}(G_2)$? и $\mathcal{L}(G_1) = \mathcal{L}(G_2)$? при дадени безконтекстни G_1, G_2.

Премахване на безполезните променливи

Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика.

Една променлива наричаме *полезна*, ако участва съществено в извеждането на някоя дума от $\Sigma^\star$ в граматиката. По-точно, $A \in V$ е полезна, ако съществува извод $S \stackrel{\star}{\Rightarrow} \alpha A \beta \stackrel{\star}{\Rightarrow} \gamma$, където $\alpha, \beta \in (V \cup \Sigma)^\star$ и $\gamma \in \Sigma^\star$.

Ясно е, че безполезните променливи могат да бъдат премахнати от граматиката, заедно с правилата в които участват, без това да се отрази на извеждания език.

За да открием полезните променливи разбиваме условието в дефиницията на две части: една променлива A е *достижима*, ако $S \stackrel{\star}{\Rightarrow} \alpha A \beta$ за $\alpha, \beta \in (V \cup \Sigma)^\star$ и *генерираща*, ако $A \stackrel{\star}{\Rightarrow} \gamma$ за $\gamma \in \Sigma^\star$.

Твърдение 8 *За всяка безконтекстна граматика $G = (V, \Sigma, R, S)$ с $L(G) \neq \emptyset$ съществува безконтекстна граматика $G' = (V', \Sigma, R', S)$, такава че $L(G') = L(G)$ и в която всяка променлива е генерираща, т.е. за всяка променлива $A \in V'$ съществува $\gamma \in \Sigma^\star$, такава че $A \stackrel{\star}{\Rightarrow}_{G'} \gamma$.*

Доказателство. Нека

$$Gen \ = \ \{A \in V \mid \exists \gamma \in \Sigma^\star \ A \stackrel{\star}{\lhd} \gamma\}.$$

Това е множеството от генериращите променливи в G. Ще го пресметнем на стъпки като дефинираме:

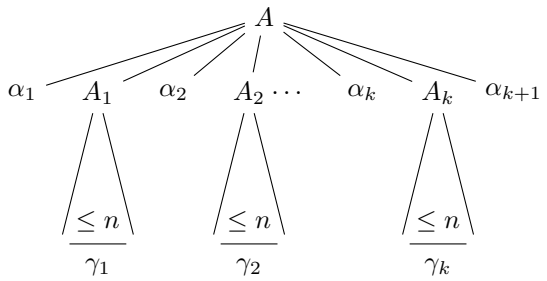
$$Gen[n] \ = \ \{A \in V \mid \exists \gamma \in \Sigma^\star \ A \stackrel{\leq n}{\lhd} \gamma\}.$$

Разбира се, $Gen[0] = \emptyset$ и също

$$Gen[n+1] \;=\; \{A \in V \mid \exists \alpha \in (Gen[n] \cup \Sigma)^\star \; A \to_G \alpha\}.$$

С други думи, една променлива A попада в $Gen[n+1]$, т.е. има дърво на извод с височина $\leq n+1$ и корен A извеждащо дума от $\Sigma^\star$, точно когато има правило в граматиката $A \to_G \alpha$, чиято дясна част α съдържа букви от Σ и променливи само от $Gen[n]$.

Ситуацията може да се илюстрира по следния начин:
($\alpha = \alpha_1 A_1 \alpha_2 A_2 \ldots \alpha_k A_k \alpha_{k+1}$ и $\alpha_i \in \Sigma^\star$, $\gamma_i \in \Sigma^\star$)



Разбира се, има по едно ребро от A към всяка буква в думите α_i. Лесно се съобразява, че:

$$Gen[0] \;\subseteq\; Gen[1] \;\subseteq\; Gen[2] \;\subseteq\; \ldots \;\subseteq\; Gen[n] \;\subseteq\; Gen[n+1] \;\subseteq\; \ldots.$$

Тъй като V е крайно множество, тази верига се стабилизира, т.е. ще дойде момент n, такъв че $Gen[n] = Gen[n+1]$ (не се добавят нови променливи). Тогава множеството Gen, което търсим съвпада с последното $Gen[n]$.

За да образуваме новата граматика G' трябва да дефинираме $V' = Gen$ и $R' = R \cap (V' \times (V' \cup \Sigma)^\star)$. В изводите от вида $S \stackrel{\star}{\Rightarrow}_G \gamma$ за $\gamma \in \Sigma^\star$ участват само променливи от Gen и от това лесно следва, че $L(G) = L(G')$.

Следствие 9 *$L(G) = \emptyset$ точно когато $S \notin Gen$.*

Този метод за проверка за празнота е значително по-ефективен от метода, който използва числото p от лемата за покачването.

Твърдение 10 *За всяка безконтекстна граматика $G = (V, \Sigma, R, S)$ съществува безконтекстна граматика $G' = (V', \Sigma, R', S)$, такава че $L(G') = L(G)$ и всяка променлива в G' е достижима, т.е. за всяка $A \in V'$ съществуват $\alpha, \beta \in (V' \cup \Sigma)^\star$, такива че $S \stackrel{\star}{\Rightarrow}_{G'} \alpha A \beta$.*

Доказателство. Нека

$$Reach \;=\; \{A \in V \mid \exists \alpha, \beta \in (V \cup \Sigma)^\star \; S \stackrel{\star}{\lhd} \alpha A \beta\}.$$

Това е множеството от достижимите променливи в G. Както в предното твърдение, пресмятаме го на стъпки:

$$Reach[n] \;=\; \{A \in V \mid \exists \alpha, \beta \in (V \cup \Sigma)^\star \; S \overset{\leq n}{\lhd} \alpha A \beta\}.$$

Започваме с $Reach[0] = \{S\}$ (тривиалното дърво с корен S) и след това

$$\begin{aligned} Reach[n+1] \;&=\; \{A \in V \mid \exists B \in Reach[n] \; B \to_G \alpha A \beta \text{ за } \alpha, \beta \in (V \cup \Sigma^\star)\} \\ &\cup\; Reach[n]. \end{aligned}$$

За разлика от предходния алгоритъм, при който си представихме как дървото на извод расте откъм корена, тук трябва да си представяме как дървото на извод расте откъм листата. За да е достижима променливата A на стъпка $n+1$ трябва да има достижима променлива B на стъпка n и също да има правило от вида $B \to_G \alpha A \beta$. Както по-горе, спираме на първото n, такова че $Reach[n] = Reach[n+1]$ и търсеният резултат $Reach$ съвпада с това последно $Reach[n]$. Забележете, че за разлика от предходното твърдение тук по дефиниция добавяме $Reach[n]$ към $Reach[n+1]$ за да постигнем растяща верига относно включването. В алгоритъма за Gen това се получава автоматично, тъй като $Gen[0] = \emptyset$. Но в случая $Reach[0] = \{S\}$ и това само по себе си не гарантира, че S ще попадне в $Reach[n]$ за $n \geq 1$.

Новата граматика G' се образува като се вземе $V' = Reach$ и правила $R' = R \cap (V' \times (V' \cup \Sigma)^\star)$. В изводите с начало S очевидно участват само достижими променливи и затова $L(G) = L(G')$.

Материалът за деветата лекция от записките:
глава 3.6 (**Извод върху синтактично дърво**), страници 114-116.
глава 3.7 (**Лема за покачването**), страници 120-124.
глава 3.8 (**Алгоритми**), страници 127-128.

За допълнително четене от учебника на Hopcroft, Motwani, Ullman:
глава 7.2 (The Pumping Lemma for Context-Free Languages).