Материалът за осмата лекция от записките:
глава 3.2 (**Контекстни граматики**), страница 102,
глава 3.3 (**Регулярни граматики**), страници 103-104,
глава 3.4 (**Безконтекстни граматики**), страници 105-107,
глава 3.5 (**Синтактични дървета**), страници 108-109,
глава **Еднозначни граматики**, страници 112-113.

За допълнително четене от учебника на Hopcroft, Motwani, Ullman:
глава 5.1 (Context-Free Grammars), подглави 5.1.1, 5.1.2, 5.1.3, 5.1.5,
глава 5.2 (Parse Trees), подглави 5.2.1 и 5.2.2.

В лекцията класифицирахме граматиките по отношение на вида на правилата, които участват в тях.

Първо разгледахме *контекстните* граматики $G = (V, \Sigma, R, S)$, в които правилата са от вида $\lambda A \rho \to \lambda \alpha \rho$, където $A \in V$, $\lambda, \rho \in (V \cup \Sigma)^\star$ и $\alpha \in (V \cup \Sigma)^+$, т.е. α е непразна дума. Идеята на този вид правила е, че можем да заменяме променливата A с думата α, единствено ако A е заградена от λ и ρ (или още: A участва с ляв контекст λ и десен контекст ρ).

Като пример разгледахме контекстна граматика за езика

$$L \;=\; \{a^n b^n c^n \mid n > 0\}$$

(страница 102 в записките). Правилото $CB \to BC$ само по себе си не е контекстно, т.е. няма вида, който се изисква в контекстните граматики. Но то може да се симулира с контекстните правила:

$$CB \to CZ, \quad CZ \to WZ, \quad WZ \to WC, \quad WC \to BC.$$

Нуждаем се от това правило, тъй като първо генерираме думата $a^n (BC)^n$, след това подреждаме B-тата и C-тата за да получим $a^n B^n C^n$ и накрая заменяме последователно всички B с b и всички C с c.

Доказателството за коректност на дадената граматика е трудно, поточно в посоката $\mathcal{L}(G) \subseteq L$. Трябва да се покаже, че при извеждане на дума от $\Sigma^\star$ в граматиката G, горните добавени правила не могат да се използват по друг начин, освен да симулират $CB \to BC$.

С подобна идея може да се покаже, че всяка граматика, в която правилата са несъкращаващи, т.е. имат вида $\alpha \to \beta$, където $|\alpha| \leq |\beta|$, е еквивалентна на контекстна граматика.

След това разгледахме *регулярните* граматики $G = (V, \Sigma, R, S)$, в които правилата са от вида $A \to aB$ и $A \to \epsilon$, където $A, B \in V$ и $a \in \Sigma$.

Изводите в такава граматика, започващи с променлива и завършващи с дума от $\Sigma^\star$ имат следния вид:

$$A \;\Rightarrow\; aA_1 \;\Rightarrow\; abA_2 \;\Rightarrow\; \ldots \;\Rightarrow\; ab\ldots cA_n \;\Rightarrow\; ab\ldots c.$$

Това много прилича на изпълнение на краен автомат, ако си мислим, че променливите отговарят на състояния и всяко приложение на правило в

извода (без последното) отговаря на прочитане на буква и преминаване в следващо състояние. Това е идеята в следващите два резултата.

Твърдение 1 *За всяка регулярна граматика G съществува НКА $\mathcal{N}$, такъв че $L(\mathcal{N}) = \mathcal{L}(G)$.*

Доказателство. При дадена регулярна $G = (V, \Sigma, R, S)$ построяваме НКА $\mathcal{N}$ по следния начин. Първо номерираме $V = \{A_0, A_1, \ldots, A_k\}$ със $S = A_0$. След това: състоянията на $\mathcal{N}$ са $Q = \{q_0, q_1, \ldots, q_k\}$ (по едно състояние за всяка променлива), началните състояния са $Q_{start} = \{q_0\}$ (това отговаря на аксиомата S), финалните състояния са $F = \{q_i \mid A_i \to_G \epsilon\}$ (отговарят на променливите A_i, за които има правило $A_i \to_G \epsilon$ в граматиката) и разширената функция на преходите се дефинира с $\Delta(q_i, x) = \{q_j \mid A_i \to_G xA_j\}$. Така имаме преход от q_i с буква x към q_j точно когато има правило $A_i \to_G xA_j$ в граматиката. Разбира се, автоматът е недетерминиран, тъй като няма ограничения за броя на правилата с една и съща променлива в лявата част. За да се провери коректността, първо се доказва

$$q_j \in \Delta^\star(\{q_i\}, \alpha) \;\leftrightarrow\; A_i \stackrel{\star}{\Rightarrow}_G \alpha A_j$$

с индукция по думата α. След това имаме:

$$\begin{aligned}
\alpha \in L(\mathcal{N}) \;&\leftrightarrow\; \Delta^\star(\{q_0\}, \alpha) \cap F \neq \emptyset \\
&\leftrightarrow\; \exists q_j \in F,\;\; q_j \in \Delta^\star(\{q_0\}, \alpha) \\
&\leftrightarrow\; \exists q_j \in F,\;\; A_0 \stackrel{\star}{\Rightarrow}_G \alpha A_j \\
&\leftrightarrow\; \exists A_j \in V,\;\; A_j \to_G \epsilon \;\;\&\;\; A_0 \stackrel{\star}{\Rightarrow}_G \alpha A_j \\
&\leftrightarrow\; S \stackrel{\star}{\Rightarrow}_G \alpha \;\leftrightarrow\; \alpha \in \mathcal{L}(G).
\end{aligned}$$

Твърдение 2 *За всеки ДКА $\mathcal{A}$ съществува регулярна граматика G, такава че $\mathcal{L}(G) = L(\mathcal{A})$.*

Доказателство. При даден ДКА $\mathcal{A} = (\Sigma, Q, q_{start}, \delta, F)$ номерираме състоянията $Q = \{q_0, q_1, \ldots, q_k\}$, $q_0 = q_{start}$ и построяваме регулярна граматика $G = (V, \Sigma, R, S)$, където $V = \{A_0, A_1, \ldots, A_k\}$, $S = A_0$ и

$$R \;=\; \{A_i \to_G xA_j \mid \delta(q_i, x) = q_j\} \;\cup\; \{A_i \to_G \epsilon \mid q_i \in F\}.$$

Както в предходното твърдение се показва, че $\delta^\star(q_i, \alpha) = q_j \;\leftrightarrow\; A_i \stackrel{\star}{\Rightarrow}_G \alpha A_j$ и като следствие се извежда, че $S \stackrel{\star}{\Rightarrow}_G \alpha \;\leftrightarrow\; \delta^\star(q_0, \alpha) \in F$, т.е. $\mathcal{L}(G) = L(\mathcal{A})$.

Забележете, че конструкцията във второто твърдение може да се приложи и за недетерминиран автомат. Единственият проблем е, че по дефиниция НКА може да има повече от едно начални състояния. Затова се добавя нова аксиома S и по едно правило $S \to_G \alpha$ за всяко правило $A_j \to_G \alpha$ с лява част, съответна на начално състояние q_j. По този начин се симулират правила от

вида $S \to_G A_j$ (наричат се преименуващи).

На страница 104 в записките е разгледан Пример 3.2, в който се построява регулярна граматика по даден ДКА.

Безконтекстни граматики

Една граматика $G = (V, \Sigma, R, S)$ е *безконтекстна*, ако правилата в R имат вида $A \to_G \alpha$, където $A \in V,\ \alpha \in (V \cup \Sigma)^\star$. По този начин, всяко срещане на променливата A в изведена дума може да се замени с α, без значение къде се намира A, т.е. независимо от контекста (оттам е наименованието). Забележете, че α може да е празната дума.

Един език $L \subseteq \Sigma^\star$ е *безконтекстен*, ако съществува безконтекстна граматика G, такава че $L = \mathcal{L}(G) = \{\omega \in \Sigma^\star \mid S \overset{\star}{\Rightarrow}_G \omega\}$.

Пример. Нека G е зададена с правилата $S \to_G AS \mid \epsilon,\ \ A \to_G aAb \mid ab$.
Изводите с начало A имат вида:

$$A \Rightarrow aAb \Rightarrow aaAbb \Rightarrow \ldots \Rightarrow a^nAb^n \Rightarrow a^{n+1}b^{n+1}.$$

Изводите с начало S, в които не се използват правилата с лява част A имат вида:

$$S \Rightarrow AS \Rightarrow A^2S \Rightarrow \ldots \Rightarrow A^nS \Rightarrow A^n.$$

За думата $aabbab \in \mathcal{L}(G)$ да разгледаме следните изводи. Започваме със $S \Rightarrow AS \Rightarrow AAS \Rightarrow AA$ и след това, в зависимост от това коя променлива заместваме, има три начина да продължим:
1. $AA \Rightarrow aAbA \Rightarrow aabbA \Rightarrow aabbab$.
2. $AA \Rightarrow Aab \Rightarrow aAbab \Rightarrow aabbab$.
3. $AA \Rightarrow aAbA \Rightarrow aAbab \Rightarrow aabbab$.

Не е трудно да се съобрази, че $\mathcal{L}(G) = (\{a^nb^n \mid n > 0\})^\star$. Забележете, че всяка дума от $\mathcal{L}(G)$ може да се представи по единствен начин като конкатенация на думи от $\{a^nb^n \mid n > 0\}$.

Твърдение 3 (Основно твърдение за безконтекстни граматики) *Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика и $\gamma_1\gamma_2 \overset{l}{\Rightarrow}_G \beta$, където $l \in \mathbb{N}$ и $\gamma_1, \gamma_2, \beta \in (V \cup \Sigma)^\star$. Тогава съществуват $l_1, l_2 \in \mathbb{N}$ и $\beta_1, \beta_2 \in (V \cup \Sigma)^\star$, такива че $\gamma_1 \overset{l_1}{\Rightarrow}_G \beta_1$, $\gamma_2 \overset{l_2}{\Rightarrow}_G \beta_2$, $l_1 + l_2 = l$ и $\beta_1\beta_2 = \beta$.*

Доказателство. Индукция по l. Вижте Твърдение 3.6 на страница 106 в записките.

Забележете, че в произволна граматика от двата извода $\gamma_1 \overset{l_1}{\Rightarrow}_G \beta_1$, $\gamma_2 \overset{l_2}{\Rightarrow}_G \beta_2$ може да се построи изводът $\gamma_1\gamma_2 \overset{l_1+l_2}{\Rightarrow}_G \beta_1\beta_2$. Основното твърдение показва обратното, т.е. така да се каже се прави подходящо разцепване на извода $\gamma_1\gamma_2 \overset{l}{\Rightarrow}_G \beta$ и тук вече е съществено, че граматиката G е безконтекстна.

Следствие 4 *Нека G е безконтекстна граматика и $X_1X_2\ldots X_k \stackrel{l}{\Rightarrow}_G \beta$, където $X_i \in V \cup \Sigma$. Съществуват думи $\beta_1, \beta_2, \ldots, \beta_k$ и естествени числа $l_1, l_2, \ldots, l_k$, такива че $X_i \stackrel{l_i}{\Rightarrow}_G \beta_i$, $\beta = \beta_1\beta_2\ldots\beta_k$ и $l = l_1 + l_2 + \ldots + l_k$.*

Доказателство. Индукция по k. Разбира се, ако $X_i \in \Sigma$, то $\beta_i = X_i$ и $l_i = 0$.

Твърдение 5 *Безконтекстните езици са затворени относно регулярните операции обединение, конкатенация и звезда на Клини.*

Идея за доказателство. За обединение: $S \to S_1, S \to S_2$, за конкатенация $S \to S_1S_2$ и за звезда на Клини: $S \to S_1S \mid \epsilon$. В по-трудната посока за конкатенацията и звездата на Клини ще трябва да се използва основното твърдение.

Следствие 6 *Всички регулярни езици са безконтекстни.*

Доказателство. Индукция по регулярните изрази с използване на твърдението. Базовите езици са безконтекстни: $S \to \epsilon$ поражда $\{\epsilon\}$, $S \to S$ поражда $\emptyset$ и $S \to a$ поражда $\{a\}$. Алтернативен начин за доказателство е да се съобрази, че всяка регулярна граматика е безконтекстна.

Синтактични дървета

Нека $G = (V, \Sigma, R, S)$ е безконтекстна граматика.

Ще дефинираме *дърво на извод* (T, λ), съвместимо с граматиката G:

1. T е крайно дърво с корен r с наредба на синовете, т.е. за всеки връх v имаме, че множеството $succ_T(v)$ от неговите синове (преките наследници) е линейно наредено.

2. $\lambda : T \to V \cup \Sigma \cup \{\epsilon\}$ е функция, задаваща етикети по върховете.

3. За корена r имаме $\lambda(r) \neq \epsilon$, т.е. $\lambda(r) \in V \cup \Sigma$.

4. Нека v е връх в T, който не е листо и $succ_T(v) = \{w_1, \ldots, w_k\}$, $k \geq 1$ са неговите синове, подредени с нарастващи индекси. Съвместимостта на (T, λ) с граматиката G изисква $\lambda(v) \to_G \lambda(w_1)\ldots\lambda(w_k)$ да е правило в G.

5. Връх w с етикет ϵ се допуска само за листата и то ако бащата v на w няма други синове, т.е. при $succ_T(v) = \{w\}$ и правило $\lambda(v) \to_G \epsilon$ се допуска $\lambda(w) = \epsilon$ (и само в такъв случай).

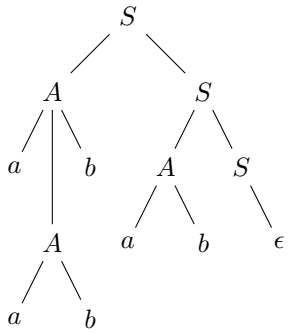
6. Нека $l_1, l_2, \ldots, l_k$ са всички листа на дървото, обходени отляво надясно. По-точно обхождането е в дълбочина на принципа пръв (най-ляв) необходен. Тогава ще казваме, че дървото (T, λ) извежда думата

$$yield(T, \lambda) = \lambda(l_1)\lambda(l_2)\ldots\lambda(l_k).$$

В записките дефиницията на синтактично дърво е на страница 108. Всеки връх в дървото формално е отъждествен с низ, който представя единствения път от корена до този връх. По този начин, коренът е празната дума ϵ и също така, ако α има $k+1$ синове, те са подредени като $\alpha 0$, $\alpha 1$, …, αk.

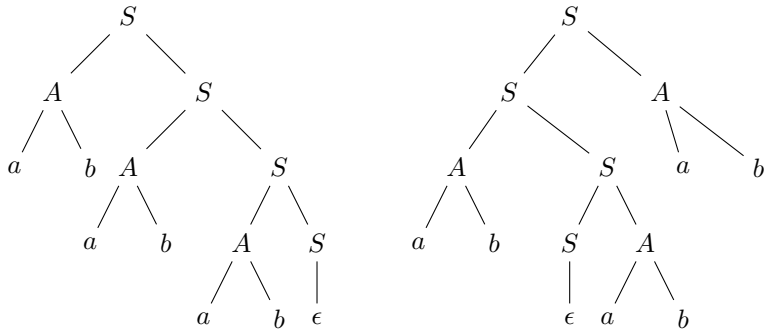
Едно листо l_i се обхожда преди l_j в точка 6. точно когато низът, представящ l_i е лексикографски по-малък от низа, представящ l_j.

Да се върнем към горния пример. Там показахме три различни линейни изводи на думата $aabbab \in \mathcal{L}(G)$. Но на тях съответства едно и също дърво на извод:



По-общо може да се покаже, че граматиката G в примера е *еднозначна*, т.е. за всяка дума от $\mathcal{L}(G)$ има единствено дърво за извод. Причината е, че за всяка дума $\alpha \in \mathcal{L}(G)$ съществуват единствено естествено k и думи $\alpha_1, \alpha_2, \ldots, \alpha_k \in \{a^n b^n \mid n > 0\}$, такива че $\alpha = \alpha_1 \alpha_2 \ldots \alpha_k$. Това определя, че по най-десния клон на дървото има точно $k+1$ върха с етикет S и накрая едно листо с етикет ϵ. От първите k от тези върхове отляво се поставят последователно единствените дървета с корен A, които извеждат думите α_i за $i = 1, 2, \ldots, k$.

Като алтернативен пример да добавим ново правило $S \to SA$ в граматиката G. Тогава отново $\mathcal{L}(G) = (\{a^n b^n \mid n > 0\})^\star$, но граматиката вече не е еднозначна. Например, за думата $ababab \in \mathcal{L}(G)$ имаме следните различни дървета на извод:



За *домашно* намерете всички останали дървета на извод на думата $ababab$, както и на горната дума $aabbab$.

Защо е важна еднозначността? Най-общо казано искаме една граматика да е еднозначна, ако дефинираме семантика с помощта на дърветата на извод.

Като пример да разгледаме граматиката

$$S \to S + S \mid S * S \mid N, \quad N \to 0 \mid 1 \mid \ \ldots \ \mid 9.$$

Тя се състои от аритметичните изрази без скоби върху операнди с по една цифра. На фигура 3.4 на страница 112 в записките са показани двете дървета на извод за думата $5 * 6 + 2$. Пресмятането на израза с дървото отляво дава погрешен резултат 40, докато дървото отдясно дава точния резултат 32.

За да въведем в граматиката приоритет на $*$ пред $+$ можем да постъпим така:

$$S \to E + S \mid E, \quad E \to E * N \mid N.$$

Езикът на граматиката не се променя, но тя вече е еднозначна. Единственото дърво на извод за $5 * 6 + 2$ е показано на фигура 3.5.

Оказва се, че задачата която решихме за конкретната граматика в общия случай е неразрешима. Не съществува алгоритъм, който разпознава дали дадена безконтекстна граматика е еднозначна.